GORKY: замер качества агента голосового ассистента

Модель агента gemini-3.5-flash-lite · коммит 015fc8c · 30.10.2026

Аннотация

Агент GORKY превращает фразу пользователя в вызов одного из восьми инструментов (создать, показать за период, найти, изменить, сменить статус, откатить, переспросить, справка), код исполняет вызов на базе. Замер — 581 кейсов в 9 наборах, 747 реплик, на настоящей модели и настоящей базе. Пройдено **557/581 = 95.9%** кейсов; выбор инструмента — macro-F1 **0.967**; медиана времени реплики — **1.12 с**.

1. Как измеряли

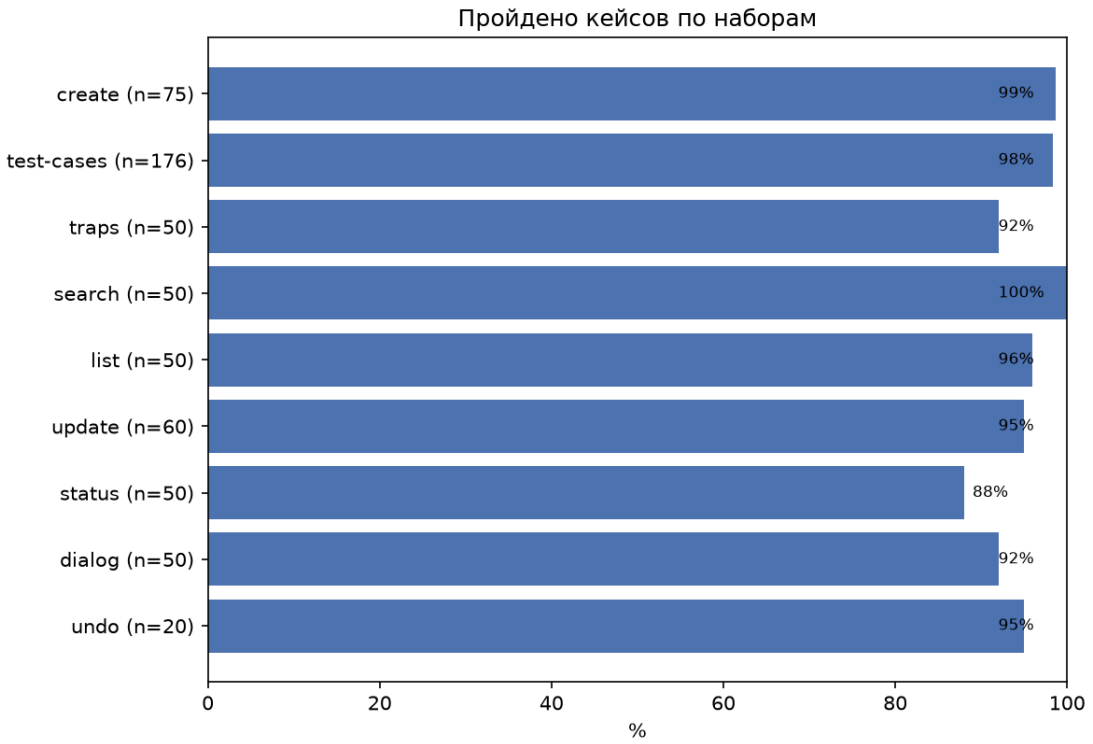
Кейс — фраза пользователя или диалог из нескольких реплик и ожидание на каждой реплике: какой инструмент вызван, значения его полей (тип, название, даты, период, запрос, цель изменения) и исход действия (исполнено, ждёт ответа, ждёт выбора). Проверяются только заданные в ожидании поля; названия и запросы — по основам слов, даты — с точностью до минуты в поясе пользователя. «Сейчас» во всех кейсах — среда 21.10.2026, 10:00, Europe/Moscow. Кейсы с записями пользователя исполняются на PostgreSQL с настоящим поиском; каждый кейс — в своей транзакции с откатом.

Набор	Что проверяет	Кейсов	Реплик
create	создание: тип, название, начало, срок, конец, «время названо»	75	75
test-cases	кейсы команды (docs/test-cases.md): примеры из задания и сценарии продукта	176	200
traps	подвохи выбора инструмента: справка, посторонняя тема, две команды, отрицание	50	50
search	поиск: запрос, фильтры, отличие от списка	50	50
list	список за период: границы периода, типы записей	50	50
update	изменение: цель (номер, «её», описание), новые значения, исходы	60	94
status	выполнено / отменено / вернуть, массовые, «не эту, а ту»	50	77
dialog	диалог: уточнение, выбор, подтверждение, отказ, смена темы	50	114
undo	«верни как было» после создания, переноса, смены статуса	20	37

Метрики: доля пройденных кейсов (кейс пройден, если верны все реплики); по инструменту — precision, recall и F1 по матрице ошибок, macro-F1 — среднее F1 по инструментам; по полю — доля верных значений (если инструмент выбран неверно, все поля реплики считаются неверными); время реплики — медиана и 95-й процентиль.

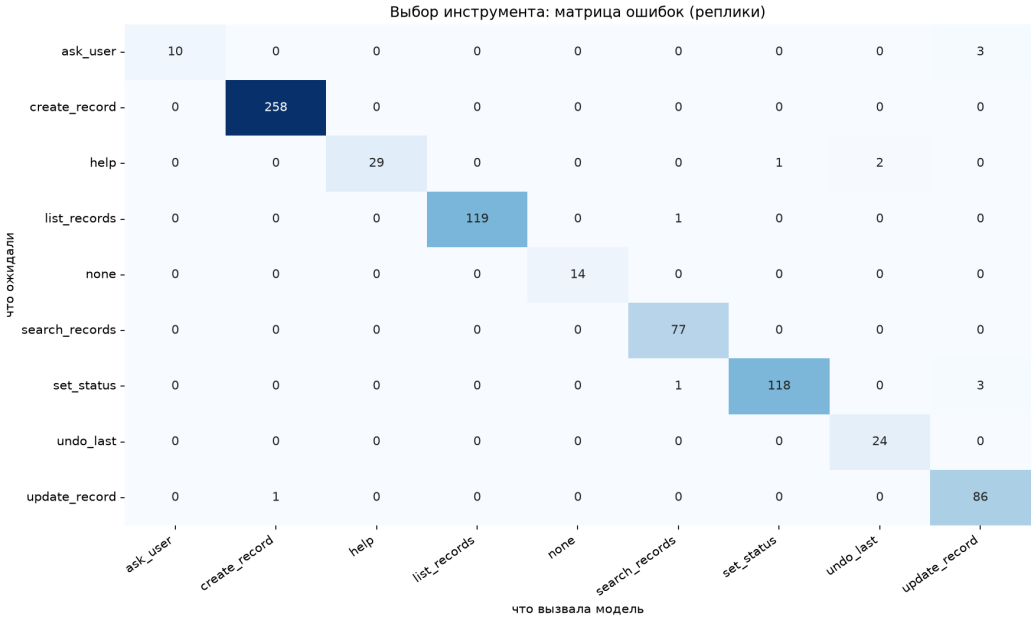
2. Результаты

Метрика	Значение
Пройдено кейсов	557/581 = 95.9%
Выбор инструмента, macro-F1	0.967
Время реплики, медиана / 95-й процентиль	1.12 с / 1.81 с
Не прогонялись (проверка в интерфейсе или другим набором)	5



Набор	Пройдено
create	74/75 = 98.7%
test-cases	173/176 = 98.3%
traps	46/50 = 92.0%
search	50/50 = 100.0%
list	48/50 = 96.0%
update	57/60 = 95.0%
status	44/50 = 88.0%
dialog	46/50 = 92.0%
undo	19/20 = 95.0%

Выбор инструмента

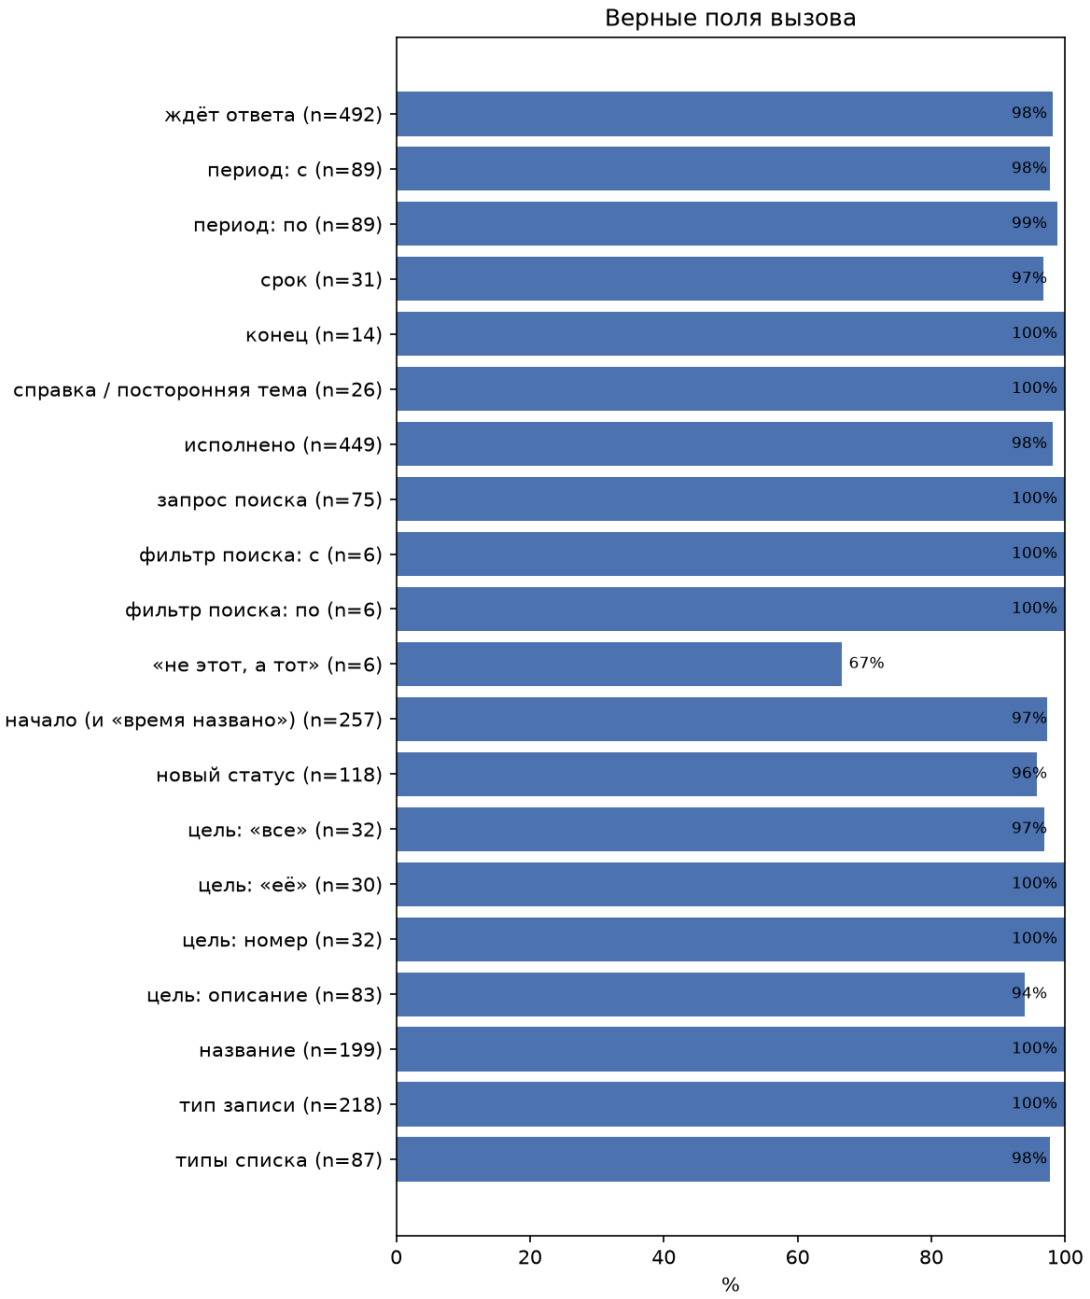


Инструмент	Precision	Recall	F1	Реплик
ask_user	1.000	0.769	0.870	13

Инструмент	Precision	Recall	F1	Реплик
create_record	0.996	1.000	0.998	258
help	1.000	0.906	0.951	32
list_records	1.000	0.992	0.996	120
none	1.000	1.000	1.000	14
search_records	0.975	1.000	0.987	77
set_status	0.992	0.967	0.979	122
undo_last	0.923	1.000	0.960	24
update_record	0.935	0.989	0.961	87

none — модель ничего не вызвала или код ответил без модели (отказ «не надо»).

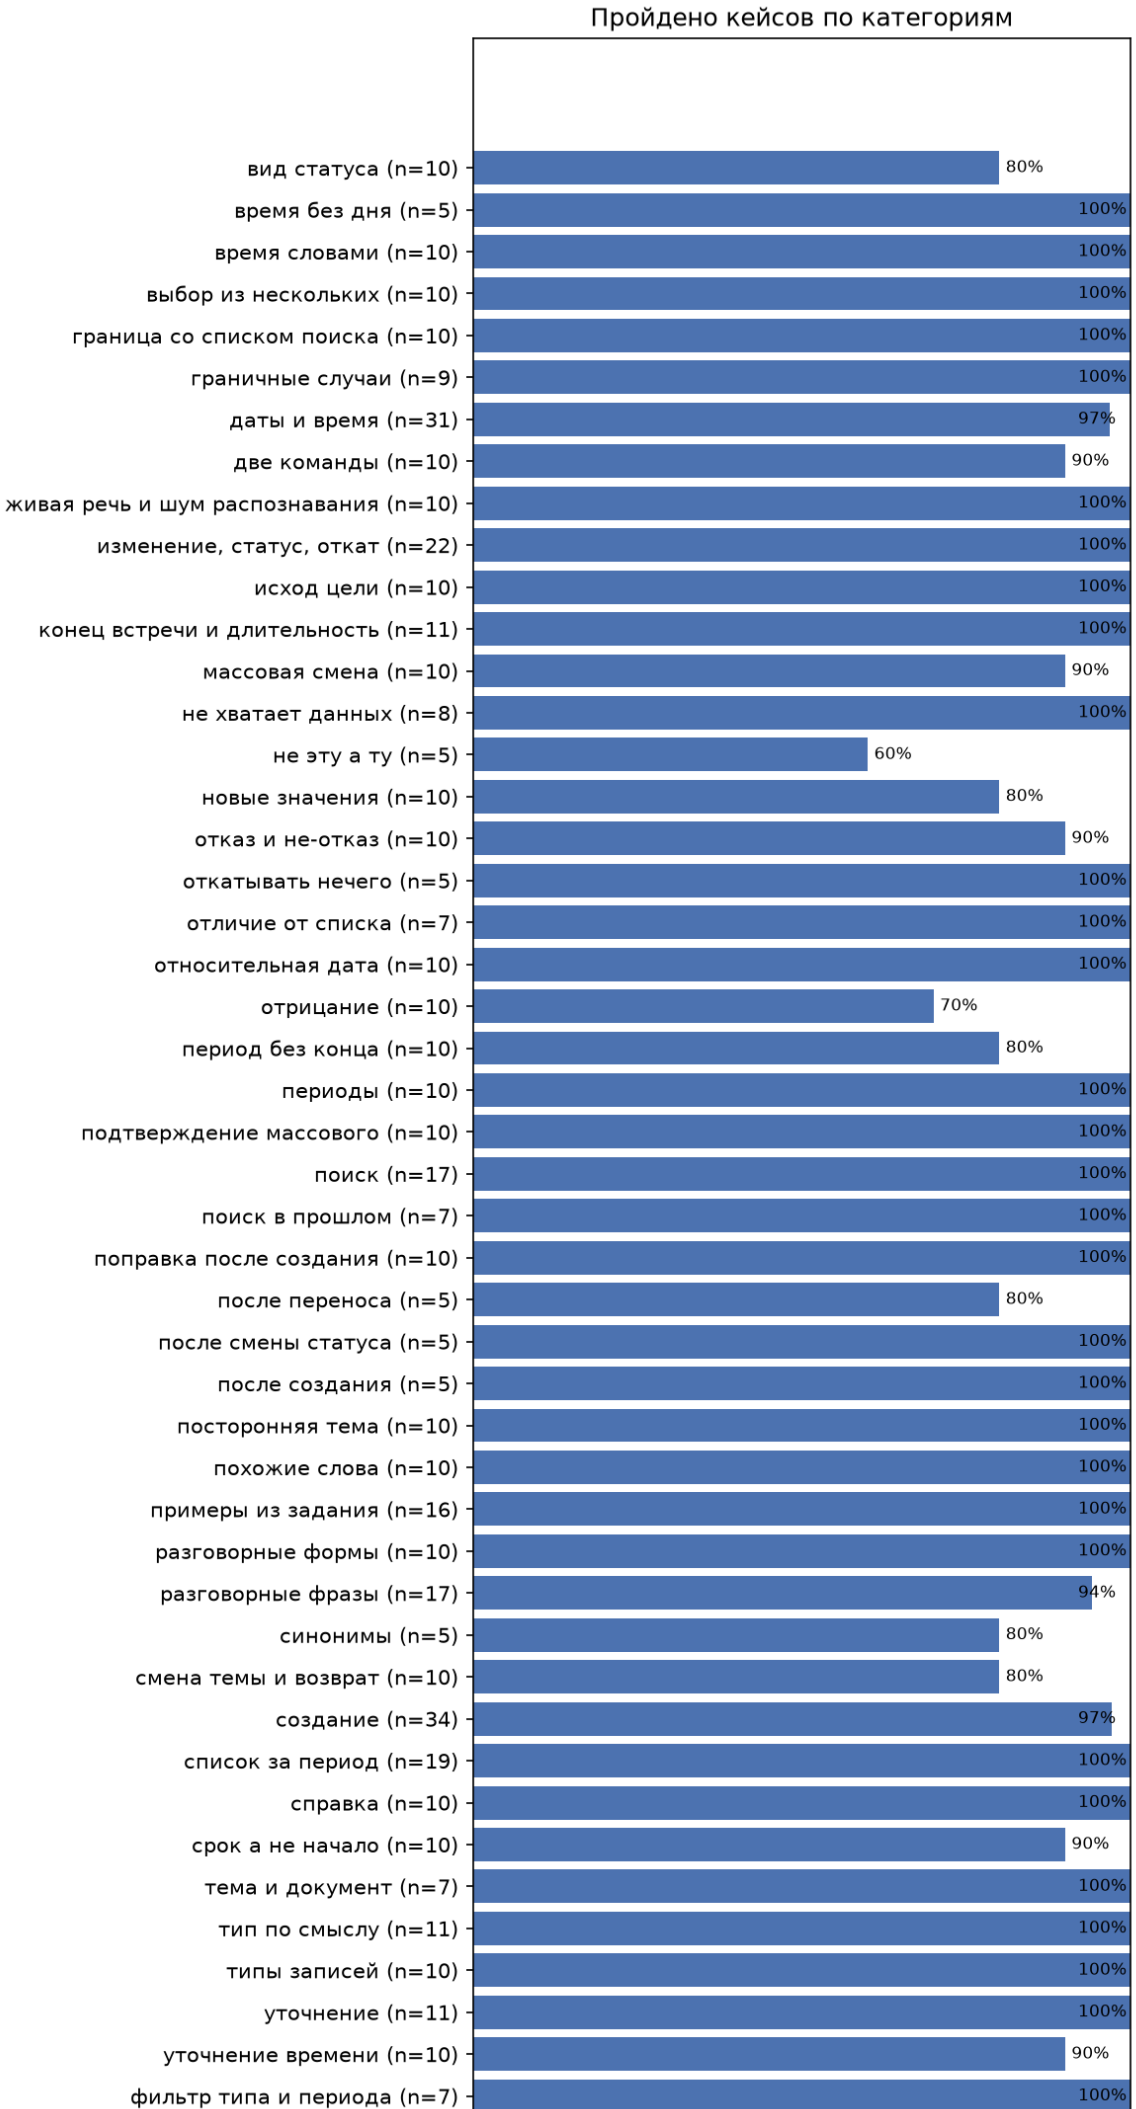
Поля вызова



Поле	Верно
ждёт ответа	483/492 = 98.2%
период: с	87/89 = 97.8%
период: по	88/89 = 98.9%

Поле	Верно
срок	30/31 = 96.8%
конец	14/14 = 100.0%
справка / посторонняя тема	26/26 = 100.0%
исполнено	441/449 = 98.2%
запрос поиска	75/75 = 100.0%
фильтр поиска: с	6/6 = 100.0%
фильтр поиска: по	6/6 = 100.0%
«не этот, а тот»	4/6 = 66.7%
начало (и «время названо»)	250/257 = 97.3%
новый статус	113/118 = 95.8%
цель: «все»	31/32 = 96.9%
цель: «её»	30/30 = 100.0%
цель: номер	32/32 = 100.0%
цель: описание	78/83 = 94.0%
название	199/199 = 100.0%
тип записи	218/218 = 100.0%
типы списка	85/87 = 97.7%

По категориям


Пройдено кейсов по категориям
вид статуса (n=10) 80%
время без дня (n=5) 100%
время словами (n=10) 100%
выбор из нескольких (n=10) 100%
граница со списком поиска (n=10) 100%
граничные случаи (n=9) 100%
даты и время (n=31) 97%
две команды (n=10) 90%
живая речь и шум распознавания (n=10) 100%
изменение, статус, откат (n=22) 100%
исход цели (n=10) 100%
конец встречи и длительность (n=11) 100%
массовая смена (n=10) 90%
не хватает данных (n=8) 100%
не эту а ту (n=5) 60%
новые значения (n=10) 80%
отказ и не-отказ (n=10) 90%
откатывать нечего (n=5) 100%
отличие от списка (n=7) 100%
относительная дата (n=10) 100%
отрицание (n=10) 70%
период без конца (n=10) 80%
периоды (n=10) 100%
подтверждение массового (n=10) 100%
поиск (n=17) 100%
поиск в прошлом (n=7) 100%
поправка после создания (n=10) 100%
после переноса (n=5) 80%
после смены статуса (n=5) 100%
после создания (n=5) 100%
посторонняя тема (n=10) 100%
похожие слова (n=10) 100%
примеры из задания (n=16) 100%
разговорные формы (n=10) 100%
разговорные фразы (n=17) 94%
синонимы (n=5) 80%
смена темы и возврат (n=10) 80%
создание (n=34) 97%
список за период (n=19) 100%
справка (n=10) 100%
срок а не начало (n=10) 90%
тема и документ (n=7) 100%
тип по смыслу (n=11) 100%
типы записей (n=10) 100%
уточнение (n=11) 100%
уточнение времени (n=10) 90%
фильтр типа и периода (n=7) 100%

3. Ошибки (24)

Набор	Кейс	Фраза	Что не так
create	cr.31	«Поставь задачу подготовить релиз до пятницы»	start: ожидалось пусто, получено 2026-10-21 00:00
test-cases	2.23ж	«В среду в 16 планёрка по сайту»	start: ожидалось 2026-10-28 16:00, получено 2026-10-21 16:00
test-cases	6.4	«слушай, а можешь напомнить про договор, ну в понедельник где-то»	start: ожидалось 2026-10-26, получено пусто
test-cases	9:в среду	«Напомни в среду в 12 оплатить счёт»	start: ожидалось 2026-10-28 12:00, получено 2026-10-21 12:00
traps	tr.21	«Покажи что у меня завтра и перенеси первую встречу на пятницу»	types: ожидалось ['meeting', 'reminder', 'task'], получено ['meeting']
traps	tr.33	«Не отменяй встречу с Иваном»	действие: ожидалось help|ask_user, получено undo_last
traps	tr.38	«Я передумал ставить встречу»	действие: ожидалось help|ask_user, получено undo_last
traps	tr.39	«Не надо отмечать выполненной задачу про отчёт»	действие: ожидалось help|ask_user, получено set_status
list	ls.26	«Что у меня есть в расписании начиная с сегодняшнего дня?»	date_from: ожидалось 2026-10-21 00:00, получено 2026-10-21 10:00
list	ls.30	«Какие напоминания стоят на будущее?»	действие: ожидалось list_records, получено search_records
update	up.24	«Напоминание про лекарства поставь на девять вечера»	действие: ожидалось update_record, получено create_record
update	up.42	«Совещание по сметам сегодня не в два, а в четыре»	target.text: нет текста; исполнение: ожидалось ok=True, получено False
update	up.47	«Перенеси ревью на пятницу и назови его «Ревью релиза»»	start: ожидалось 2026-10-23, получено пусто
status	st.2	«Готово, смету отправил»	действие: ожидалось set_status, получено search_records
status	st.7	«Нет, не сделал, верни её в активные»	status: ожидалось active, получено done
status	st.33	«Очисти завтрашний день»	действие: ожидалось set_status, получено update_record
status	st.44	«Ой, не с Ярославом, а с Ростиславом»	действие: ожидалось set_status, получено update_record
status	st.45	«Нет, я Григорию позвонил, не Георгию»	действие: ожидалось set_status, получено update_record
status	st.47	«Закрой задачу про печать»	исполнение: ожидалось ok=True, получено False
dialog	dl.5	«В восемь»	start: ожидалось 2026-10-22 08:00, получено 2026-10-22 20:00
dialog	dl.40	«В 15»	действие: ожидалось ask_user, получено update_record
dialog	dl.43	«в 16»	действие: ожидалось ask_user, получено update_record
dialog	dl.49	«в 16»	действие: ожидалось ask_user, получено update_record
undo	un.9	«Срок по декларации подвинь на воскресенье»	deadline: ожидалось 2026-10-25, получено пусто; исполнение: ожидалось ok=True, получено False; ожидание ответа: ожидалось None, получено choice

4. Ограничения

— Кейсы наборов, кроме test-cases, сгенерированы моделью Gemini 3.8 Flash (high reasoning) по контрактам репозитория (docs/contracts/); ожидание — то, что однозначно

следует из контракта. Набор test-cases составлен командой.

— Один прогон, повторов 1: разброс ответов модели между прогонами не измерен.

— Измерена одна модель агента; другие модели не сравнивались.

— Проверяются вызов инструмента, его поля и исход действия на настоящей базе, а не формулировка ответа пользователю.

— Голос (распознавание и синтез речи) не измерялся: на вход агенту подаётся текст.

— Время реплики — от текста пользователя до готового ответа, с исполнением на локальной базе; без пауз, которые прогон делает между вызовами модели.

Данные: наборы — backend/eval/datasets/agent/, ответы агента на каждый кейс — backend/eval/results/agent/final.jsonl, отчёты по наборам — backend/eval/reports/agent-final/.